PASSMATE · 요약본

데이터분석 준전문가 (ADsP)

급할 때 빠르게 훑어보는 핵심 정리 · 15개 주제

1과목 데이터 이해

1-01 데이터와 정보
1-02 데이터베이스
1-03 빅데이터의 이해
1-04 위기 요인과 통제 방안
1-05 데이터 사이언티스트와 비식별화

2과목 데이터 분석 기획

2-01 분석 주제 4유형
2-02 분석 방법론
2-03 과제 발굴: 하향식과 상향식
2-04 우선순위와 거버넌스

3과목 데이터 분석

3-01 척도와 표본추출
3-02 가설검정
3-03 회귀분석
3-04 시계열과 차원 축소
3-05 분류 모형과 평가
3-06 군집·연관분석과 전처리

1과목 · 데이터 이해

1-01 데이터와 정보

- 정량 데이터: 수치·기호로 표현 (저장·검색·분석 쉬움) / 정성 데이터: 언어·문자 등 (저장·분석 어려움)
- DIKW 피라미드: Data(사실) → Information(의미 있는 가공) → Knowledge(정보를 구조화한 통찰) → Wisdom(창의적 아이디어)
- 암묵지(체화된 지식)와 형식지(문서화된 지식)의 SECI 상호작용: 공통화 → 표출화(암묵지→형식지) → 연결화 → 내면화(형식지→암묵지)

암기 DIKW = 데이터 → 정보 → 지식 → 지혜

1-02 데이터베이스

- 데이터베이스 특징: 통합된 데이터(중복 없음), 저장된 데이터, 공용 데이터, 변화되는 데이터
- OLTP = 실시간 거래 처리(갱신 위주) / OLAP = 다차원 분석(조회 위주)
- 기업 내부 활용: ERP(전사 자원), CRM(고객 관계), SCM(공급망), BI(의사결정 지원), KMS(지식 관리)

암기 DB 특징 = 통합·저장·공용·변화되는 데이터

1-03 빅데이터의 이해

- 3V: Volume(규모), Variety(다양성), Velocity(속도) / 여기에 Value(가치), Veracity(정확성)를 더해 5V
- 본질적 변화 4가지: 사전처리 → 사후처리, 표본조사 → 전수조사, 질 → 양, 인과관계 → 상관관계
- 빅데이터 활용 기본 테크닉: 연관규칙 학습, 유형분석, 유전 알고리즘, 기계학습, 회귀분석, 감정분석, 소셜 네트워크 분석

암기 3V = Volume · Variety · Velocity

1-04 위기 요인과 통제 방안

- 사생활 침해 → 개인정보 사용 주체의 책임제로 전환 (동의제 → 책임제)
- 책임 원칙 훼손(예측만으로 처벌) → 결과 기반 책임 원칙 고수
- 데이터 오용 → 알고리즘 접근 허용, 알고리즈미스트가 해석·검증

암기 사생활 침해 → 동의제에서 책임제로

1-05 데이터 사이언티스트와 비식별화

- 하드 스킬: 빅데이터 이론 지식, 분석 기술 숙련 / 소프트 스킬: 통찰력 있는 분석, 설득력 있는 전달, 다분야 협력
- 가명처리(이름 바꾸기), 총계처리(합계·평균으로), 데이터 삭제, 데이터 범주화(35세 → 30대), 데이터 마스킹(홍**)

암기 비식별화 5가지: 가명 · 총계 · 삭제 · 범주화 · 마스킹

2과목 · 데이터 분석 기획

2-01 분석 주제 4유형

- 대상 알고 방법 앎 → 최적화(Optimization)
- 대상 알고 방법 모름 → 솔루션(Solution)
- 대상 모르고 방법 앎 → 통찰(Insight)
- 대상 모르고 방법 모름 → 발견(Discovery)

암기 대상·방법 둘 다 앎 = 최적화, 둘 다 모름 = 발견

2-02 분석 방법론

- KDD: 데이터셋 선택 → 전처리 → 변환 → 데이터 마이닝 → 해석·평가
- CRISP-DM 6단계: 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개
- 빅데이터 분석 방법론 5단계: 분석 기획 → 데이터 준비 → 데이터 분석 → 시스템 구현 → 평가 및 전개
- 개발 모델: 폭포수(단계 순차), 프로토타입(빠르게 만들어 개선), 나선형(반복하며 위험 관리)

암기 CRISP-DM = 업무 이해 → 데이터 이해 → 준비 → 모델링 → 평가 → 전개

2-03 과제 발굴: 하향식과 상향식

- 하향식: 문제가 주어지고 해법을 찾음. 문제 탐색 → 문제 정의 → 해결방안 탐색 → 타당성 검토
- 비즈니스 모델 캔버스 문제 탐색 5영역: 업무, 제품, 고객, 규제와 감사, 지원 인프라
- 상향식: 데이터 자체를 관찰해 인사이트 도출, 비지도학습 주로 활용, 디자인 사고의 발산 단계

암기 하향식 = 문제 탐색 → 정의 → 해결방안 → 타당성

2-04 우선순위와 거버넌스

- 우선순위 평가 축: 시급성(전략적 중요도)과 난이도. 시급성 기준 III → IV → II, 난이도 기준 III → I → II
- 분석 성숙도 4단계: 도입 → 활용 → 확산 → 최적화
- 분석 준비도 6영역: 분석 업무, 인력·조직, 분석 기법, 분석 데이터, 분석 문화, IT 인프라
- 사분면: 준비도↓성숙도↓ 준비형 / 준비도↓성숙도↑ 정착형 / 준비도↑성숙도↓ 도입형 / 둘 다↑ 확산형
- 분석 조직 구조: 집중형, 기능 중심형, 분산형 / 데이터 거버넌스 구성요소: 원칙, 조직, 프로세스

암기 성숙도 = 도입 → 활용 → 확산 → 최적화

3과목 · 데이터 분석

3-01 척도와 표본추출

- 명목척도(성별) / 순서척도(만족도 순위) / 구간척도(온도, 0이 절대 기준 아님) / 비율척도(무게·키, 절대 0 있음)
- 단순랜덤 / 계통추출(일정 간격) / 집락추출(군집 통째로) / 층화추출(겹치지 않는 층으로 나눠 층마다 랜덤)

암기 온도 = 구간척도 (0이 '없음'이 아님)

3-02 가설검정

- 제1종 오류(α): 참인 귀무가설을 기각 / 제2종 오류(β): 거짓인 귀무가설을 채택 / 검정력 = 1 - β
- p-value가 유의수준보다 작으면 귀무가설 기각
- 상관계수 -1 ~ 1. 피어슨 = 연속형·선형 관계, 스피어만 = 순위(서열) 자료

암기 p값 < 유의수준 → 귀무가설 기각

3-03 회귀분석

- 가정: 선형성, 독립성, 등분산성, 정규성
- 결정계수 R^2: 0~1, 클수록 설명력 높음. 변수를 넣을수록 R^2는 줄지 않으므로 수정 결정계수로 비교
- 다중공선성: VIF 10 이상이면 의심 / 변수 선택: 전진선택, 후진제거, 단계적 선택 (AIC·BIC 작을수록 좋음)

암기 VIF 10 이상 = 다중공선성 의심

3-04 시계열과 차원 축소

- 정상성: 평균·분산 일정, 공분산은 시차에만 의존. 평균이 안 맞으면 차분, 분산이 안 맞으면 변환
- ARIMA(p, d, q): p = AR 차수, d = 차분 횟수, q = MA 차수 / 분해 요인: 추세·계절·순환·불규칙
- 주성분분석: 누적 기여율(보통 70~90%)과 스크리 플롯으로 주성분 수 결정

암기 평균 일정 X → 차분 / 분산 일정 X → 변환

3-05 분류 모형과 평가

- 로지스틱 회귀: 결과가 범주형, 오즈·시그모이드 함수 사용
- 의사결정나무 분류 기준: 지니지수, 엔트로피, 카이제곱 통계량 p값 / 회귀나무: F통계량, 분산 감소량
- 앙상블: 배깅(붓스트랩 표본으로 여러 모델 후 투표), 부스팅(틀린 데이터에 가중치), 랜덤 포레스트(배깅 + 변수 무작위 선택)
- 정확도 (TP+TN)/전체, 정밀도 TP/(TP+FP), 재현율=민감도 TP/(TP+FN), 특이도 TN/(TN+FP)
- ROC 곡선: x축 1-특이도(FPR), y축 민감도(TPR), 아래 면적 AUC가 1에 가까울수록 좋음

암기 정밀도 TP/(TP+FP) · 재현율 TP/(TP+FN)

3-06 군집·연관분석과 전처리

- 계층적 군집 연결법: 최단, 최장, 평균, 와드(군집 내 오차제곱합 증가가 최소)
- k-means: k를 미리 정함, 초기값·이상치에 민감 / 혼합분포 군집은 EM 알고리즘
- 지지도 $P(A \cap B)$, 신뢰도 $P(B|A) = P(A \cap B)/P(A)$, 향상도 = 신뢰도/P(B) → 1이면 독립, 1보다 크면 양의 관계
- 이상치: Q1 - 1.5×IQR 미만 또는 Q3 + 1.5×IQR 초과 / 결측치: 완전 제거, 평균 대치, 다중 대치

암기 향상도 1 = 서로 독립